

Numerikus Számítások

9. előadás

Csókás Eszter

Szegedi Tudományegyetem
Informatika Intézet
Számítógépes Optimalizálási Tanszék



Sajátérték, sajátvektor korlátok folyt./ismétlés

1.1. Definíció. A $\lambda \in \mathbb{C}$ szám sajátértéke az $A \in \mathbb{C}^{n \times n}$ mátrixnak, ha van olyan **0-tól különböző** $v \in \mathbb{C}^n$ (oszlop)vektor, amelyre

$$Av = \lambda v.$$

1.2. Állítás. Egy $A \in \mathbb{C}^{n \times n}$ mátrix sajátértékei pontosan a

$$p_A(x) := |\mathbf{A} - x\mathbf{I}|$$

polinom gyökei. (A p_A polinomot az A mátrix **karakterisztikus polinomjának** nevezzük.)

1.3. Következmény. Mivel egy $n \times n$ -es mátrix karakterisztikus polinomja n -edfokú, ezért az algebra alaptétele szerint egy $n \times n$ -es **komplex mátrixnak n sajátértéke van**. Természetesen ez úgy értendő, hogy a karakterisztikus polinom többszörös gyökeit többszörös sajátértékeknek tekintjük.

1.4. Definíció. A $\lambda \in \mathbb{C}$ szám sajátértéke az $A \in \mathbb{C}^{n \times n}$ mátrixnak, ha van olyan 0-tól különböző $\mathbf{v} \in \mathbb{C}^n$ (oszlop)vektor, amelyre

$$[\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.]$$

1.5. Állítás. Egy $A \in \mathbb{C}^{n \times n}$ mátrixnak végtelen sok sajátvektora van (amennyiben a mátrixnak legalább egy sajátértéke létezik (ami komplex számok felett garantált)).

Miért végtelen sok?

- Ha $\mathbf{v}$ sajátvektor, akkor bármely $c \neq 0$ skalárral vett többszöröse ($c\mathbf{v}$) is sajátvektor, hiszen

$$\mathbf{A}(c\mathbf{v}) = c(\mathbf{A}\mathbf{v}) = c(\lambda\mathbf{v}) = \lambda(c\mathbf{v}).$$

1.6. Tétel. *Ha az $\mathbf{A} \in \mathbb{C}^{n \times n}$ nonszinguláris mátrixnak λ sajátértéke és $\mathbf{v}$ egy hozzá tartozó sajátvektor, akkor az $\mathbf{A}^{-1}$ -nek sajátértéke az $1/\lambda$ és $\mathbf{v}$ itt is hozzá tartozó sajátvektor.*

Bizonyítás.

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v} \Rightarrow \mathbf{A}^{-1}\mathbf{A}\mathbf{v} = \mathbf{A}^{-1}\lambda\mathbf{v} \Rightarrow \mathbf{v} = \mathbf{A}^{-1}\lambda\mathbf{v}.$$

Osszunk át a nemzérus λ -val. ■

Direkt meghatározás végeessége

Emlékeztető: $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ egyenlet baloldalán levő n -edfokú polinomot az $\mathbf{A}$ mátrix karakterisztikus polinomja. Ez egy n -edfokú polinomot eredményez - ezt láttuk. Ez döntő szerepet játszik abban, hogy miért nem létezik egy általános, véges számú alpműveletből álló „direkt képlet” a sajátértékek meghatározására minden mátrixméret esetén.

1.7. Tétel. Abel-Ruffini tétel:

- $n \leq 4$ esetén: Léteznek zárt alakú megoldóképletek (másodfokú, harmadfokú és negyedfokú egyenletekhez), így a sajátértékek elvben „direkt” módon, gyökvonásokkal kifejezhetők.
- $n \geq 5$ esetén: Az Abel-Ruffini tétel kimondja, hogy az általános ötödfokú (vagy magasabb fokú) polinomok gyökei nem fejezhetők ki az alpműveletek és gyökvonások véges kombinációjával.

1.8. Következmény. Nincs olyan általános algoritmus, amely véges számú algebrai lépésben (összeadás, szorzás, gyökvonás) pontosan megadná bármely 5×5 -ös vagy nagyobb mátrix sajátértékeit.

A hatványmódszer

Háttére

A gyakorlatban sok esetben csak bizonyos sajátértékek meghatározására van szükség. A *hatványmódszer* a legnagyobb abszolút értékű sajátérték meghatározására szolgál. Az alapalgoritmus a következő iteráción alapul:

$$\mathbf{y}^k = \mathbf{A}\mathbf{x}^k, \mathbf{x}^{k+1} = \mathbf{y}^k / \|\mathbf{y}^k\|.$$

A kiindulási vektor olyan kell hogy legyen, hogy $\mathbf{x}^0 \neq 0$, és $\mathbf{x}^0$ nem merőleges a legnagyobb abszolút értékű sajátértékhez tartozó sajátvektorra. A módszer másik neve *von Miseses vektoriterációja*. Ha $|\lambda_1| > |\lambda_i|$ minden $i = 2, \dots, n$ -re, és a λ_1 -hez tartozó sajátvektor u_1 , akkor

$$\lim_{k \rightarrow \infty} \underbrace{\text{sign}(\lambda_1)^k \mathbf{x}^k}_{\text{vektor}} = u_1, \text{ es } \lim_{k \rightarrow \infty} \underbrace{\|\mathbf{y}^k\| / \|\mathbf{x}^k\|}_{\text{érték}} = \underbrace{|\lambda_1|}_{\text{érték}}.$$

Ha λ_2 a második legnagyobb abszolútértékű sajátérték, akkor a konvergencia sebességére érvényes:

$$\frac{\mathbf{y}_i^k}{\mathbf{x}_i^k} = \lambda_1 + \mathcal{O}\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right), \text{ illetve } \underbrace{\frac{(\mathbf{x}^k)^T \mathbf{y}^k}{(\mathbf{x}^k)^T \mathbf{x}^k}} = \lambda_1 + \mathcal{O}\left(\left|\frac{\lambda_2}{\lambda_1}\right|^{2k}\right).$$

Itt $\frac{(\mathbf{x}^k)^T \mathbf{y}^k}{(\mathbf{x}^k)^T \mathbf{x}^k}$ az ún. *Rayleigh-féle hányados*.

Tegyük fel, hogy $\mathbf{A}$ reguláris, ekkor minden sajátértéke nullától különböző. Ekkor az $\mathbf{Ax} = \lambda \mathbf{x}$ egyenletből

$$\mathbf{x} = \mathbf{A}^{-1}(\lambda \mathbf{x}) = \lambda \mathbf{A}^{-1} \mathbf{x}$$

adódik, és innen

$$\underbrace{\lambda^{-1} \mathbf{x}} = \lambda^{-1} \lambda \mathbf{A}^{-1} \mathbf{x} = \underbrace{\mathbf{A}^{-1} \mathbf{x}}.$$

Eszerint ha az $\mathbf{A}$ mátrix sajátértéke λ , és az ehhez tartozó sajátvektor $\mathbf{x}$, akkor az $\mathbf{A}^{-1}$ mátrix egy sajátértéke λ^{-1} az $\mathbf{x}$ sajátvektorral. Ezen a felismerésen alapul az *inverz hatványmódszer*, vagy más néven a *Wieland-féle inverz iteráció*:

$$\mathbf{Ay} = \mathbf{x}^k, \underbrace{\mathbf{x}^{k+1} = \mathbf{y} / \|\mathbf{y}\|},$$

amely tehát a legkisebb abszolút értékű sajátértéket és a hozzá tartozó sajátvektort közelíti meg. Az $\mathbf{A} - \sigma \mathbf{I}$ mátrixra alkalmazva a hatványmódszert az $\mathbf{A}$ mátrixnak a σ számtól legtávolabbi sajátértékét kapjuk, a hozzá tartozó sajátvektorral.

A következő egyszerű Matlab program a hatványmódszer segítségével meghatározza a legnagyobb abszolút értékű sajátértéket az iterált véletlen vektor minden komponenséből:

```
function lambda = hatv(A);  
x = [rand(1) rand(1) rand(1)]';  
for i=1:(100) ←  
    y = A*x;  
    lambda = y./x;  
    r = (x'*y)/(x'*x)  
    x = y/norm(y);  
end
```

Hajtsuk végre a programot a sajátértékek korlátainál vizsgált mátrixra:

$$\mathbf{A} = \begin{pmatrix} 1 & 1 & -1 \\ 2 & -2 & 0 \\ 1 & 0 & 5 \end{pmatrix}.$$

A kapott becslések a maximális abszolút értékű sajátértékre a komponensenkénti becsléssel, és a Rayleigh hányadossal az első néhány iterációban:

iteráció	1	2	3	4	5
komponensenkénti	40.7831	7.8748	4.9474	-28.6488	4.7033
Rayleigh	-0.4284	-1.1691	0.4980	3.2966	4.1575

iteráció	6	7	8	9	10
komponensenkénti	6.4596	-499.5966	5.0727	7.5500	4.8025
Rayleigh	4.6264	4.6601	4.7092	4.7009	4.7091

iteráció	1	2	3	4	5
komponensenkénti	40.7831	7.8748	4.9474	-28.6488	4.7033
Rayleigh	-0.4284	-1.1691	0.4980	3.2966	4.1575

iteráció	6	7	8	9	10
komponensenkénti	6.4596	-499.5966	5.0727	7.5500	4.8025
Rayleigh	4.6264	4.6601	4.7092	4.7009	4.7091

A maximális abszolút értékű sajátértékhez tartozó kapott sajátvektor pedig

$$[-0.2807, -0.0826, 0.9562]^T.$$

A helyes sajátérték 4.7066, és a hozzá tartozó sajátvektor

$$[-0.2805, -0.0837, 0.9562]^T.$$

Hasonlósági transzformáció

Hasonlósági transzformáció

A sajátértékszámítás egyik kulcsfogalma a hasonlóság, amelyre, mint később látjuk majd, a numerikus módszereinket is építjük majd.

3.1. Definíció. Legyen $\mathbf{A}$ tetszőleges mátrix, $\mathbf{T}$ pedig tetszőleges reguláris mátrix. Az

$$\mathbf{A} \mapsto \mathbf{T}^{-1}\mathbf{A}\mathbf{T}$$

hozzárendelést *hasonlósági transzformációnak* nevezzük.

Azt mondjuk, hogy $\mathbf{A}$ hasonló a $\mathbf{B}$ mátrixhoz, ha létezik olyan reguláris $\mathbf{T}$ mátrix, hogy $\mathbf{B} = \mathbf{T}^{-1}\mathbf{A}\mathbf{T}$.

Ennek rövid jelölése a továbbiakban: $\mathbf{A} \sim \mathbf{B}$.

A sajátérték feladattal kapcsolatban a legfontosabb tény, hogy **a sajátértékek invariánsak a hasonlósági transzformációkra**.

Tekintsük most a **B** mátrix egy λ sajátértékét. Erre érvényes, hogy:

$$\mathbf{B}\mathbf{y} = \lambda\mathbf{y} \quad \Rightarrow \quad \boxed{\mathbf{T}^{-1}\mathbf{A}\mathbf{T}}\mathbf{y} = \lambda\mathbf{y} \quad \text{f.} \quad \Rightarrow \quad \mathbf{A}(\underbrace{\mathbf{T}\mathbf{y}}_{\mathbf{v}}) = \lambda(\underbrace{\mathbf{T}\mathbf{y}}_{\mathbf{v}}).$$

(Handwritten notes: A red arrow points from $\mathbf{y}$ to $\mathbf{T}^{-1}\mathbf{A}\mathbf{T}$. Blue annotations show $\mathbf{A}\mathbf{T}\mathbf{y} = \mathbf{T}\lambda\mathbf{y}$ and $\mathbf{A}(\mathbf{T}\mathbf{y}) = \lambda(\mathbf{T}\mathbf{y})$ with $\mathbf{v}$ under $\mathbf{T}\mathbf{y}$.)

3.2. Következmény. Legyenek $\mathbf{A}, \mathbf{B} \in \mathbb{C}^{n \times n}$ tetszőleges mátrixok.

- (i) Ha $\mathbf{A} \sim \mathbf{B}$, akkor $\lambda_j(\mathbf{A}) = \lambda_j(\mathbf{B})$, azaz sajátértékeik megegyeznek.
- (ii) Ha $\mathbf{A} \sim \mathbf{B}$ és $\mathbf{A}$ egy sajátvektorrendszere $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$, akkor $\mathbf{B}$ sajátvektorrendszere fölírható $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ formában, ahol

$$\boxed{\mathbf{v}_j = \mathbf{T}^{-1}\mathbf{u}_j}$$

bármely $1 \leq j \leq n$ esetén.

Eszerint a hasonlósági transzformációk azok, amelyekkel egy mátrixot átalakíthatunk olyan kedvezőbb alakra, amelyről a sajátértékeket már könnyen le tudjuk olvasni.

Abból, hogy az **A** és a **B** mátrix sajátértékei megegyeznek, még *nem* következik, hogy hasonlóak is.

3.3. Példa. *Indirekt úton könnyen belátható, hogy az*

$$A = \begin{pmatrix} \textcircled{1} & 1 \\ 0 & \textcircled{1} \end{pmatrix} \quad \sim \quad I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$
$$\lambda(A) = \{1, 1\} \quad \lambda(I) = \{1, 1\}$$

mátrix nem hasonló az I egységmátrixhoz.

Ebből az is következik, hogy hasonlósági mátrixokkal nem mindig tudunk egy mátrixból hasonlósági transzformációkkal egy diagonális mátrixot kapni. Márpedig nyilvánvaló, hogy a diagonális mátrixok sajátértékei a diagonálisbeli számok, és a sajátvektorok pedig az ezeknek megfelelő egységvektorok.

A sajátvektorok definíciójából adódik, hogy ha az A mátrix sajátvektoraiból állítjuk össze az $\mathbf{X}$ mátrixot, akkor pl.

$$\mathbf{A}\mathbf{X} = \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix} \begin{pmatrix} \textcircled{1} & \textcircled{1} \\ \textcircled{1} & \textcircled{-1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \textcircled{2} & 0 \\ 0 & \textcircled{4} \end{pmatrix} = \mathbf{X}\mathbf{D},$$

λ_1 λ_2

ahol $\mathbf{D}$ az a diagonális mátrix, amely $\mathbf{A}$ sajátértékeit tartalmazza. Tekintsük általános esetben a következő mátrixokat:

$$\mathbf{D} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n), \quad \text{és} \quad \mathbf{X} = (x_1, x_2, \dots, x_n),$$

ahol λ_i az A mátrix i -edik sajátértéke, és x_i a hozzá tartozó sajátvektor. Ha az $\mathbf{X}$ mátrix reguláris, akkor

$$\mathbf{A} = \mathbf{X}\mathbf{D}\mathbf{X}^{-1}, \quad \text{és} \quad \underbrace{\mathbf{D} = \mathbf{X}^{-1}\mathbf{A}\mathbf{X}}_{\text{}}$$

Következmény

3.4. Tétel. *Az A mátrix akkor és csak akkor diagonalizálható, ha létezik n elemű lineárisan független sajátvektor-rendszere.*

Általános esetben: a legtöbb, ami elérhető, az az, hogy az A mátrixot hasonlósági transzformációkkal ún. *Jordan alakra* hozzuk: olyan mátrixot kapunk, amelyben a főátló mellett a felső mellékátló tartalmazhat még nullától különböző elemeket. Sajnos a Jordan alakra hozás numerikusan nem stabilis, ezért nem szokás használni.

Tudunk stabil eljárást: hasonlósági transzformációkkal egy mátrixot felső háromszögmátrixszá alakít (ez az ún. *Schur-féle normálalak*), és ekkor is a főátló elemei adják a sajátértékeket.

LR transzformáció

LR transzformáció

- H. Rutishauser által 1959-ben megadott eljárás
- az LR felbontáson alapul
- egy olyan mátrixsorozatot ad meg, amellyel meghatározhatók az $\mathbf{A}$ mátrix sajátértékei

Az eljárás az $\mathbf{A}_1 = \mathbf{A}$ mátrixból indul, és a következő két lépésből áll:

$$\begin{aligned}\mathbf{A}_k &= \mathbf{L}_k \mathbf{R}_k, & (\text{felbontás}) \\ \mathbf{A}_{k+1} &= \mathbf{R}_k \mathbf{L}_k. & (\text{értékkadás } \mathbf{A}_{k+1} \text{-nek!})\end{aligned}$$

Tehát az aktuális mátrixot felbontjuk egy alsó- és egy felső háromszögmátrixra, majd a következő iterált mátrixot úgy kapjuk, hogy ezeket fordított sorrendben összeszorozzuk. Az $\mathbf{L}_k$ alsó háromszögmátrix főátlójában egyesek vannak.

Legyen $\mathbf{T}_k = \mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k$ és $\mathbf{U}_k = \mathbf{R}_k \mathbf{R}_{k-1} \cdots \mathbf{R}_1$. Ekkor érvényes a következő:

4.1. Segédteétel. Ha minden $k = 1, 2, \dots$ indexre létezik a fent definiált $\mathbf{A}_k$ mátrix, akkor

- (i) az $\mathbf{A}$ mátrix hasonló $\mathbf{A}_k$ -hoz,
- (ii) $\boxed{\mathbf{A}_k = (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_{k-1})^{-1} \mathbf{A}_1 (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_{k-1}) = \mathbf{T}_{k-1}^{-1} \mathbf{A}_1 \mathbf{T}_{k-1}}$, 
- (iii) $\boxed{\mathbf{A}_1^k = \mathbf{T}_k \mathbf{U}_k}$.

Bizonyítás. Az (i), állítás adódik az (ii),-ből. A többire alkalmazzunk teljes indukciót. A $k = 2$ esetben mindkettő nyilvánvalóan teljesül. Vegyük először az (ii), állítást. Mivel $\mathbf{L}_k$ reguláris, ezért

$\mathbf{A}_{k+1} = \mathbf{L}_k^{-1} \mathbf{A}_k \mathbf{L}_k$ és az indukciós feltevés miatt

$$\begin{aligned}\mathbf{A}_{k+1} &= \mathbf{L}_k^{-1} (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_{k-1})^{-1} \mathbf{A}_1 (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_{k-1}) \mathbf{L}_k \\ &= (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k)^{-1} \mathbf{A}_1 (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k) \\ &= \mathbf{T}_k^{-1} \mathbf{A}_1 \mathbf{T}_k.\end{aligned}$$

Tehát az (ii), állítás igaz a $k + 1$ esetre is. Tekintsük most az (iii), pontot hasonló gondolatmenetet követve:

$$\begin{aligned}\mathbf{A}_1^{k+1} &= \mathbf{A}_1 \mathbf{A}_1^k = \mathbf{A}_1 \mathbf{T}_k \mathbf{U}_k = \mathbf{A}_1 (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k) (\mathbf{R}_k \mathbf{R}_{k-1} \cdots \mathbf{R}_1) \\ (ii) \quad &= (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k) \mathbf{A}_{k+1} (\mathbf{R}_k \mathbf{R}_{k-1} \cdots \mathbf{R}_1) \\ &= (\mathbf{L}_1 \mathbf{L}_2 \cdots \mathbf{L}_k) \mathbf{L}_{k+1} \mathbf{R}_{k+1} (\mathbf{R}_k \mathbf{R}_{k-1} \cdots \mathbf{R}_1) = \mathbf{T}_{k+1} \mathbf{U}_{k+1}.\end{aligned}$$

Amivel a harmadik részt is igazoltuk.

2. az **A** sajátértékeit alkalmasan indexelve érvényes

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| > 0$$

(amiből adódik, hogy A_1 reguláris és sajátértékei mind valósak és egyszeresek), és

3. megadható az $\mathbf{A}$ mátrixot diagonalizáló olyan $\mathbf{X}$ mátrix, amellyel egyrészt

$$\mathbf{X}^{-1}\mathbf{A}_1\mathbf{X} = \mathbf{D} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n),$$

másrészt létezik mind az $\mathbf{X} = \tilde{\mathbf{L}}\tilde{\mathbf{R}}$, mind az $\mathbf{X}^{-1} = \bar{\mathbf{L}}\bar{\mathbf{R}}$ trianguláris felbontás, akkor az $\{\mathbf{A}_k\}$, $\{\mathbf{R}_k\}$ és az $\{\mathbf{L}_k\}$ mátrix sorozatok mind konvergensek:

$$A = L \underset{\substack{\uparrow \\ I}}{Q}$$

$$\lim_{k \rightarrow \infty} \mathbf{A}_k = \lim_{k \rightarrow \infty} \mathbf{R}_k =$$

$$\begin{pmatrix} \lambda_1 & x & \cdots & x \\ 0 & \lambda_2 & \cdots & x \\ 0 & 0 & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

és

$$\lim_{k \rightarrow \infty} \mathbf{L}_k = I.$$

- az első két sorozat egy olyan mátrixhoz tart, amelynek főátlójában az $\mathbf{A}_1$ mátrix sajátértékei vannak nagyság szerint rendezve
- az LR algoritmus legfőbb hátránya, hogy még erős feltételek teljesülése esetén is előfordulhat, hogy valamely k -ra az $\mathbf{A}_k$ iterált mátrix nem bontható fel $\mathbf{L}_k\mathbf{R}_k$ alakban
- megállási feltétel: egy lehetőség például az, hogy az iterált $\mathbf{A}_k$ mátrix főátló alatti elemei négyzetösszege kisebb egy előre megadott kis $\varepsilon > 0$ számnál
- műveletigény: általános $\mathbf{A}$ mátrixra $\mathcal{O}(n^3)$, felső Hessenberg alakú $\mathbf{A}$ mátrixra $\mathcal{O}(n^2)$, és *tridiagonális mátrixra* (amelynek a főátló mellett legfeljebb a mellékátlókban vannak nem nulla elemei) pedig $\mathcal{O}(n)$

Példa

Nézzük meg, hogy az LR transzformáció hogyan működik a következő mátrixra:

$A = [1 \ 1 \ -1; 2 \ -2 \ 0; 1 \ 0 \ 5]$ → ennek sajátértékei: -2.5440, 1.8374 és 4.7066

it.	R_{11}	R_{22}	R_{33}	eltérés
1	2.0000	2.0000	5.5000	17.3750
2	2.7500	3.0000	-2.6667	20.3343
3	6.0000	-2.5556	1.4348	5.0446
4	5.3333	-2.5761	1.6013	0.5999
5	4.8125	-2.5159	1.8170	0.2339
6	4.8052	-2.5719	1.7801	0.0513
7	4.7135	-2.5217	1.8509	0.0187
8	4.7259	-2.5622	1.8169	0.0052
9	4.7052	-2.5301	1.8480	0.0019
10	4.7109	-2.5546	1.8281	0.0006

it.	R_{11}	R_{22}	R_{33}	eltérés
20	4.7066	-2.5445	1.8370	4.5111e-007
30	4.7066	-2.5445	1.8370	6.7061e-010
40	4.7066	-2.5445	1.8370	1.0004e-012
50	4.7066	-2.5445	1.8370	1.4923e-015

→ már 5 iteráció után felismerhetők a sajátértékek és 10 iteráció alatt megkezdődött a pontosság állnak már rendelkezésre
→ a sajátértékek az abszolút értékek csökkenő sorrendje szerint rendezettek

Matlab eljárások mátrixok sajátértékei meghatározására

Matlab eljárások

A Matlabban a sajátértékszámításra a következő fontosabb eljárások állnak rendelkezésre:

<code>eig</code>	az összes sajátérték és sajátvektor meghatározása
<code>hess</code>	Hessenberg alakra hozás
<code>schur</code>	Schur-féle normálalakra (felső háromszögmátrix) hozás
<code>eigs</code>	néhány sajátérték és sajátvektor
<code>condeig</code>	a sajátértékek kondíciószáma
<code>poly</code>	a mátrix karakterisztikus polinomját adja
<code>eigshow</code>	illusztrálja a 2×2 -es mátrixok sajátértékeit

Keressük a $A = \begin{bmatrix} 1 & 1 & -1; & 2 & -2 & 0; & 1 & 0 & 5 \end{bmatrix}$ mátrix sajátértékeit és sajátvektorait. Csak a sajátértékeket kapjuk az `eig` utasítással (a sajátérték angolul eigenvalue):

```
>> eig(A)
ans =
    -2.5440
     1.8374
     4.7066
```

→ az `eig` utasítás 16 különböző algoritmusból választja ki az adott feladathoz legjobban igazodót, amellyel az a leghatékonyabban megoldható

→ jó alternatívája az `eigs` parancs, amely nagy méretű, vagy ritka mátrixokra lényegesen gyorsabban ad választ

Keressük a $A = [1 \ 1 \ -1; 2 \ -2 \ 0; 1 \ 0 \ 5]$ mátrix sajátértékeit és sajátvektorait. Csak a sajátértékeket kapjuk az `eig` utasítással (a sajátérték angolul eigenvalue):

```
>> eig(A)
```

```
ans =
```

```
-2.5440
```

```
1.8374
```

```
4.7066
```

→ az `eig` utasítás 16 különböző algoritmusból választja ki az adott feladathoz legjobban igazodót, amellyel az a leghatékonyabban megoldható

→ jó alternatívája az `eigs` parancs, amely nagy méretű, vagy ritka mátrixokra lényegesen gyorsabban ad választ

Ha a sajátvektorokat is kérjük, akkor a következő formában kell írni:

```
>> [V,D] = eig(A)
```

```
V =
```

0.2623	-0.8539	-0.2805
-0.9644	-0.4450	-0.0837
-0.0348	0.2700	0.9562

```
D =
```

-2.5440	0	0
0	1.8374	0
0	0	4.7066

Karakterisztikus polinom

A sajátértékek meghatározásának egy másik útját jelenti, amikor az **A** mátrix karakterisztikus polinomját határozzuk meg, majd annak gyökeit:

```
>> poly(A)
```

```
ans =
```

```
1.0000 -4.0000 -8.0000 22.0000
```

```
>> roots(ans)
```

Sajátértékek (gyökök)

```
ans =
```

```
4.7066
```

```
-2.5440
```

```
1.8374
```

Figyeljük meg, hogy az előző utasítás eredményére hivatkozhatunk az `ans` névvel. Az eljárás értékéből levon az, hogy a `poly` használja a `eig` utasítást...

Schur-féle normál alak

A Schur-féle normálalakra is hozhatjuk a mátrixunkat:

```
>>schur(A)
```

```
ans =
```

```
-2.5440    0.8748   -0.8048  
         0    1.8374    1.8939  
         0         0    4.7066
```

Nézzük meg az alakját! Hol vannak a sajátértékek?

→ a főátlójából olvashatók le a sajátértékek!

LR-transzformáció

A Matlab maga nem tartalmazza az LR transzformációs iterációt, de nem nehéz ennek egy egyszerű programját megírni:

```
function R = lr(A);
```

```
for k=1:10
```

```
    [L,R] = lu(A) ← felbontás
```

```
    A = R*L ← értékelés
```

```
end
```

$A = R$ ← sajátérték főátló

$L = I$

