

Numerikus Számítások

13. előadás

Csókás Eszter

Szegedi Tudományegyetem
Informatika Intézet
Számítógépes Optimalizálási Tanszék



Interpoláció - ismétlés, bevezető

Legkisebb négyzetek módszere

Legkisebb négyzetek módszere

Most azt vizsgáljuk, amikor

- több feltételünk van, mint változónk;
- de ilyen feladat nem oldható meg minden pontban való illeszkedéssel.
- Ekkor viszont, feltehető a következő kérdés:
→ mi az a megoldás, amely a lehető legkisebb eltérést ad a kitűzött egyenlet két oldala között

Például: olyan $Ax = b$ egyenlet, amelyben a b vektor magasabb dimenziójú, mint az x .

Gyakori eset az, amikor az adatvektort egy véletlen modell generálja, azaz $y = Ax + \varepsilon$, ahol ε a zajt reprezentáló vektor, ismert statisztikai jellemzőkkel.

Amennyiben az ε komponensei független valószínűségi változók nulla várható értékkel és konstans varianciával, a Gauss-Markov tétel állítása szerint a legjobb torzítatlan lineáris becslést az x vektorra úgy kaphatjuk meg, ha a reziduál $\|y - Ax\|_2$ kettes normáját minimalizáljuk.

Mivel ebben az esetben az

$$\|y - Ax\|_2^2 = \|\varepsilon\|_2^2 = \sum_i \varepsilon^2$$

is minimális, így az x vektor meghatározásának ezt a módját a *legkisebb négyzetek módszerének*, az ennek megfelelő x vektort pedig *legkisebb négyzetes megoldásnak* nevezzük. A megoldás előállításának módját adja meg a következő:

1.1. Tétel. *Tegyük fel, hogy $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$, és $A^H A$ nem szinguláris. Ekkor $\|b - Ax\|_2$ a minimumát abban az x^* vektorban veszi fel, amelyikre az*

$$A^H A x^* = A^H b$$

normálegyenlet *teljesül*.

1.2. Tétel. Tegyük fel, hogy $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$, és $A^H A$ nem szinguláris. Ekkor $\|b - Ax\|_2$ a minimumát abban az x^* vektorban veszi fel, amelyekre az $A^H Ax^* = A^H b$ normálegyenlet teljesül.

Bizonyítás. Legyen $r = b - Ax$, és $r^* = b - Ax^*$. Ekkor a normálegyenletből az adódik, hogy $A^H r^* = 0$, és emiatt

$$(r^* - r)^H r^* = (A(x - x^*))^H r^* = (x - x^*)^H A^H r^* = 0.$$

Ebből az következik, hogy

$$\begin{aligned} \|r\|_2^2 &= r^H r + r^{*H}(r^* - r) = r^{*H} r^* - (r^* - r)^H r \\ &= r^{*H} r^* + (r^* - r)^H (r^* - r) = \|r^*\|_2^2 + \|r^* - r\|_2^2. \end{aligned}$$

Azaz $\|r\|_2^2 \geq \|r^*\|_2^2$, és az egyenlőség pontosan akkor teljesül, ha $r^* = r$. Ebben az esetben azonban

$$A^H A(x - x^*) = A^H (r - r^*) = 0,$$

és az $A^H A$ regularitása miatt a minimum csak az $x^* = x$ pontban áll elő.

A normálegyenlet együtthatómátrixa, $A^H A$ Hermite-szimmetrikus, mivel

$$A^H A = A^H (A^H)^H = (A^H A)^H.$$

Ezen túl pozitív szemidefinit is, mivel $x^H A^H A x = \|Ax\|_2^2 \geq 0$ teljesül minden x -re. Ha az A rangja n , akkor $A^H A$ pozitív definit, mert $x^H A^H A x = 0$ -ból $Ax = 0$ következik, és így $x = 0$.

Amennyiben a normálegyenlet együtthatómátrixa jól kondicionált (mint pl. a spline közelítések esetén), akkor ebből közvetlenül meghatározható a legkisebb négyzetes megoldás.

→ az a módja, hogy képezzük a Cholesky-felbontást: $A^H A = LL^H$, majd a megfelelő háromszögmátrixokkal megoldjuk a kapott egyenleteket

- Gyakran a kapott normálegyenletek rosszabban kondicionáltak, mint a kiindulási optimalizálási feladat,
 - a kondíciósám lényegében a négyzete lesz a korábbiak.
-
- Görbeillesztési feladatokban a közelítő függvényeket szokás alapfüggvények lineáris kombinációjaként megadni.
 - Amikor ezek az alapfüggvények hasonló jellegűek, akkor az ezekből adódó egyenletek rendszerint rosszul kondicionáltak.

Példa

Határozzuk meg tízes alapú, 5 hosszú mantisszával és optimális kerekítéssel a legjobban illeszkedő egyenest a $(3.32, 4.32)$, $(3.33, 4.33)$ és $(3.34, 4.34)$ pontokhoz.

Példa

Határozzuk meg tízes alapú, 5 hosszú mantisszával és optimális kerekítéssel a legjobban illeszkedő egyenest a (3.32, 4.32), (3.33, 4.33) és (3.34, 4.34) pontokhoz.

A megoldás az egy meredekségű, és egy tengelymetszetű egyenes. A feladat az $s = x_1 t + x_2$ egyenlet együtthatóinak meghatározása, annak az $Ax = b$ egyenletnek a megoldása, ahol

$$A = \begin{pmatrix} 3.32 & 1 \\ 3.33 & 1 \\ 3.34 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 4.32 \\ 4.33 \\ 4.34 \end{pmatrix}.$$

Az $A^H Ax = A^H b$ normálegyenletre azt kapjuk, hogy

$$A^H A \approx \begin{pmatrix} 33.267 & 9.99 \\ 9.99 & 3 \end{pmatrix}, \quad A^H b \approx \begin{pmatrix} 43.257 \\ 12.99 \end{pmatrix}.$$

A Cholesky felbontás az $A^H A \approx LL^T$ eredményt adja, ahol:

$$L \approx \begin{pmatrix} 5.7678 & 0 \\ 1.7320 & 0.014142 \end{pmatrix},$$

az első egyenletrendszerből azt kapjuk, hogy

$$L^{-1}A^H b \approx \begin{pmatrix} 7.4997 \\ 0.0010 \end{pmatrix},$$

és ebből a hamis megoldás:

$$x = (L^H)^{-1} L^{-1} A^H b \approx \begin{pmatrix} 1.2790 \\ 0.070817 \end{pmatrix}.$$

A probléma oka az $A^H A$ mátrix rosszul kondicionáltsága: $\text{cond}_\infty(A^H A) \approx 3.1 \cdot 10^6$ mellett nem lehetett pontos értékes jegyet várni.

Ha a számításokat a Matlab alapbeállításával hajtottuk végre, akkor már 11 jegyre helyes eredményt kaptunk: $x = (1.000000000000349, 0.99999999998837)^T$. Ez megint csak összhangban van a fenti kondíciószámmal.

Jegyezzük meg, hogy jobban jártunk volna, ha a megoldást $s = x_1(t - 3.33) + x_2$ alakban keressük. Különböznél pedig a korábban megállapítottak értelmében rosszul kondicionált mátrixra érdekesebb a QR felbontást használni.

Polinomok legkisebb négyzetek módszere alapján való illesztésével a Matlabban a `polyfit` utasítás foglalkozik. Feltesszük, hogy az interpolációs alappontok páronként különbözők, és hogy egy n -edfokú $p(x)$ polinomot szeretnénk megkeresni az $\{x_i, y_i\}_{i=1}^m$ pontokhoz úgy, hogy $p(x_i) \approx y_i$ teljesüljön. Konkrétan az utasítás olyan polinomot határoz meg, amelyre a

$$\sum_{i=1}^m (p(x_i) - y_i)^2$$

függvény minimális. A szintaxisa

$$p = \text{polyfit}(x, y, n).$$

Ha az n paramétert úgy adjuk meg, hogy $n \geq m - 1$, akkor interpolációs polinomot kapunk. Másrészt magas fokszámú interpolációs polinomok nagyon oszcillálók lehetnek, ezért általában alacsony fokszámú polinommal való közelítést szoktak előnyben részesíteni.

Interpoláció a Matlabban

A Matlab egy- két- és magasabb dimenziós interpolációt támogat. A legegyszerűbb esetben az

$$y_0 = \text{interp1}(x, y, x_0)$$

utasítás az $x(i)$, $y(i)$ pontokra vonatkozó interpolációs polinomot meghatározza, kiértékeli azt az x_0 pontban, és az eredményt értékül adja az y_0 változónak. Az $x(i)$ értékeknek szigorúan növekvő sorozatot kell alkotniuk. A negyedik argumentumban megadhatjuk az interpoláció típusát aposztrófok között:

- 'cubic' köbös interpoláció,
- 'linear' lineáris interpoláció (alapértelmezés),
- 'nearest' a legközelebbi szomszédos interpoláció,
- 'spline' köbös spline interpoláció.

A lineáris interpoláció egyenes szakaszokból álló törtvonalat hoz létre, a legközelebbi szomszéd az adott ponthoz legkisebb távolságú alappont függvényértékét adja.

A következő Matlab példa a szinusz függvényt közelíti a $[0, \pi]$ intervallumban, 5 alappontra támaszkodva.

```
>> x = [0 pi/4 3*pi/8 3*pi/4 pi]; y = sin(x);  
>> xi = linspace(0,pi,30);  
>> ys = interp1(x,y,xi,'spline');  
>> yn = interp1(x,y,xi,'nearest');  
>> yl = interp1(x,y,xi,'linear');  
>> xx = linspace(0,pi,50);  
>> plot(xx,sin(xx),'-',x,y,'.','MarkerSize',20), hold on  
>> set(gca,'XTick',x), set(gca,'XGrid','on')  
>> set(gca,'XTickLabel','0|pi/4|3pi/8|3pi/4|pi')  
>> h = plot(xi,ys,'x',xi,yn,'o',xi,yl,'+');  
>> axis([-0.25 3.5 -0.1 1.1])  
>> legend(h,'spline','nearest','linear'), hold off
```

A nearest interpoláció ennek alig nevezhető, durva közelítést ad. Ezzel szemben a spline jó leírást ad a függvényről, és a lineáris közelítés is csak a nagyon görbült részen tér el lényegesen.



A Matlabban két eljárás is van kétdimenziós interpolációra: a `griddata` és az `interp2`. Az előbbi utasítás szintaxisa

$$ZI = \text{griddata}(x, y, z, XI, YI),$$


ahol az `x`, `y` és `z` vektorok tartalmazzák az adatot, `ZI` az interpolált függvényértékek mátrixa az `XI` és `YI` mátrixoknak megfelelően – amelyeket rendszerint a `meshgrid` paranccsal töltünk ki. A hatodik, szöveges argumentum adja meg az alkalmazott közelítő módszert:

- 'linear' háromszög alapú lineáris interpoláció (alapértelmezés),
- 'cubic' háromszög alapú köbös interpoláció,
- 'nearest' a legközelebbi szomszédos interpoláció.

Az `interp2`-nek hasonló argumentum-listája van, de azt igényli, hogy `x` és `y` monoton mátrixok legyenek, amilyent a `meshgrid` is előállít.

```
>> x = rand(100,1)*4-2; y = rand(100,1)*4-2;  
>> z = x.*exp(-x.^2-y.^2);  
>> hi = -2:.1:2;  
>> [XI,YI] = meshgrid(hi);  
>> ZI = griddata(x,y,z,XI,YI);  
>> mesh(XI,YI,ZI), hold  
>> plot3(x,y,z,'o'), hold off
```

Az alábbi ábrán az eredeti adatpontokat körök jelzik, az interpolált felületet pedig a rács. Az `interp3` és `interp $n$` eljárások három-, illetve n -dimenziós interpolációra használhatók.



Összegzés, kitekintés

Fejlett numerikus számítások

- Lineáris egyenletrendszerek iterációs módszerei
- Befoglalások
- Automatikus deriválás
- Numerikus deriválás és integrálás
- Taylor módszerre épülő számítások
- Nemlineáris rendszerek
- Globális optimalizáló eljárások
- Differenciálegyenletes modellek

Szóval változó, érzékeny rendszerekben optimum keresés. Populációk egyensúly fenntartása. Iterációs módszerek, gyorsasága pontosságért. Zérushely keresés és szélsőérték keresés, optimum bármi folytonos cuccnak. Alapvetően OptAlgon kívül ez lesz az első alkalom hogy optimalizáló algoritmust látunk, nem egyenleteket.